

Clustering com K-Means


Aprendizado não supervisionado aplicado à base de dados Iris, explorando o efeito de K e da padronização dos atributos.

PROFESSOR

Ahmed Ali Abdalla Esmin

ALUNO

Tobias Maugus Bueno Cougo




Objetivo da atividade

Compreender na prática como o K-Means forma grupos e como a escolha de K afeta o resultado.



Agrupar sem rótulos

Aplicar o K-Means à base Iris usando só os atributos — nunca a espécie real.



Testar vários K

Rodar o algoritmo para diferentes K e observar como isso muda os grupos.



Avaliar com métricas

Usar WCSS, Silhouette Score e o Método do Cotovelo para apoiar a escolha de K.



Medir o efeito da padronização

Comparar os resultados com e sem StandardScaler antes de agrupar.

Como o K-Means agrupa os dados

1

Escolhe K centróides

Posições iniciais (geralmente aleatórias) para os K centros dos grupos.

2

Atribui cada ponto

Cada amostra é associada ao centróide mais próximo (distância Euclidiana).

3

Recalcula os centróides

Cada centróide vira a média dos pontos atribuídos a ele.


4

Repete até convergir

Passos 2 e 3 se repetem até os centróides pararem de mudar.

K precisa ser escolhido antes de rodar — o algoritmo não decide isso sozinho.

Antes → Depois da convergência



A base Iris, agora sem rótulos

Mesma base do TP01 — 150 amostras, 4 atributos — mas usada em um cenário não supervisionado.

150

amostras

4

atributos numéricos

3

espécies (desconhecidas p/ o modelo)




As espécies reais não entram no treinamento


O K-Means recebe apenas os 4 atributos numéricos (comprimento/largura de sépala e pétala). O rótulo de espécie (setosa, versicolor, virginica) é guardado à parte e usado só depois, para conferir o quanto os clusters encontrados se aproximam da realidade — nunca como entrada do algoritmo.

Escolhendo o número de clusters (K)

Método do Cotovelo (WCSS) e Silhouette Score, calculados para dados brutos e padronizados.



Silhouette Score por valor de k



K ESCOLHIDO


k = 3

O cotovelo aparece entre k=2 e k=3 nos dois cenários. O Silhouette é maior em k=2 (setosa é bem isolada), mas k=3 vem logo em seguida — e é o valor coerente com as 3 espécies conhecidas.

A partir de k=6, o Silhouette só piora — sinal de que estamos fragmentando demais.

O efeito de K no resultado

Mesmos dados, projetados em 2D via PCA, agrupados com $K = 2, 3, 4$ e 5 .



k=2 isola setosa do resto. **k=3** separa também versicolor/virginica. A partir de **k=4/5**, o algoritmo passa a fatiar uma região naturalmente contínua, sem estrutura real correspondente.

Modelo final (k = 3)

Comparação dos clusters encontrados com as espécies reais — usada só para análise.

Espécie \ Cluster	0	1	2
Setosa	50	0	0
Versicolor	0	48	2
Virginica	0	14	36

14 amostras de Virginica caíram no cluster de Versicolor — as demais, 100% corretas.

78,85

WCSS (inércia)

0,5528



Silhouette Score

0,7302

Adjusted Rand Index


Clusters encontrados vs. espécies reais

Como os 4 atributos não cabem num gráfico 2D, usamos PCA para reduzir a dimensionalidade.



O efeito (surpreendente) da normalização

Padronizar os atributos, neste caso, piorou a concordância com as espécies reais.



POR QUE ISSO ACONTECE?

Os atributos de pétala têm naturalmente mais variância nos dados brutos — e são justamente os mais discriminativos entre espécies.

Ao padronizar, a largura da sépala — pouco discriminativa — passa a pesar igual, diluindo o sinal mais útil para separar os grupos.

Padronizar continua sendo boa prática geral — mas seu efeito deve ser sempre conferido, não assumido.

CONCLUSÃO

O que aprendemos



K pequeno funcionou melhor aqui

k=2 e k=3 concentram os melhores resultados; a partir de k=4 o modelo fragmenta grupos que não existem de fato.



Padronizar nem sempre ajuda

Quando a escala natural do atributo está ligada à sua relevância, normalizar pode diluir informação útil.



K-Means tem limitações claras

Exige K definido a priori, assume clusters esféricos/de tamanho parecido e não modela bem sobreposição entre grupos reais.

Obrigado!

Tobias Maugus Bueno Cougo