

# Trabalho Prático 02 – Clustering K-Means

GCC 128 – Inteligência Artificial | Prof. Ahmed Ali Abdalla Esmin  
Aluno: Tobias Maugus Bueno Cougo

## 1. Metodologia

Aplicou-se o **K-Means** à base **Iris** (150 amostras, 4 atributos), em cenário não supervisionado: os rótulos de espécie não entraram no treinamento, apenas na análise posterior. Testaram-se vários valores de K, usando **Método do Cotovelo** (WCSS) e **Silhouette Score** como apoio à escolha, e comparou-se o efeito de padronizar os atributos (*StandardScaler*). Para visualização (não incluída aqui por espaço), os 4 atributos foram reduzidos a 2D via **PCA** — gráficos completos, incluindo o cotovelo e o silhouette para k=1 a 10, estão no notebook.

## 2. Resultados

**Tabela 1.** WCSS e Silhouette por k (dados brutos) — faixa de maior interesse.

| k          | 2      | 3      | 4      | 5      | 6      |
|------------|--------|--------|--------|--------|--------|
| WCSS       | 152,35 | 78,85  | 57,23  | 46,46  | 39,04  |
| Silhouette | 0,6810 | 0,5528 | 0,4981 | 0,4912 | 0,3648 |

**Tabela 2.** Modelo final (k=3): dados brutos vs. padronizados.

| Versão dos dados | WCSS   | Silhouette | ARI vs. espécie real |
|------------------|--------|------------|----------------------|
| Brutos           | 78,85  | 0,5528     | 0,7302               |
| Padronizados     | 139,82 | 0,4599     | 0,6201               |

**Tabela 3.** Matriz de contingência: espécie real × cluster (k=3, dados brutos).

| Espécie real \ Cluster | 0  | 1  | 2  |
|------------------------|----|----|----|
| Setosa                 | 50 | 0  | 0  |
| Versicolor             | 0  | 48 | 2  |
| Virginica              | 0  | 14 | 36 |

## 3. Análise e Conclusão

**Influência de K:** o Cotovelo e o Silhouette concordam entre si — ambos indicam k=2 como o valor geometricamente mais compacto/separado (a espécie *setosa* é muito distinta das demais), com k=3 logo atrás. Como essas métricas não "sabem" que existem 3 espécies biológicas, a escolha final de K combina esse critério estatístico com o conhecimento de domínio; a partir de k=4 os clusters extras apenas fragmentam artificialmente uma região naturalmente contínua, sem ganho de interpretabilidade.

**Efeito da normalização:** contraintuitivamente, padronizar os atributos **piorou** a concordância com as espécies reais (ARI de 0,73 para 0,62 — Tabela 2). Isso ocorre porque os atributos de pétala, mais discriminativos entre espécies, têm naturalmente maior variância nos dados brutos; padronizar iguala esse peso ao da largura da sépala, pouco discriminativa, diluindo o sinal mais útil. A padronização continua sendo boa prática geral (essencial quando atributos têm unidades muito diferentes), mas seu efeito deve ser sempre conferido, não assumido.

**Características dos grupos e limitações:** o cluster de *setosa* é perfeito (Tabela 3); o principal desvio ocorre entre *versicolor* e *virginica*, que têm sobreposição real nos atributos — não uma falha do algoritmo. De forma geral, o K-Means exige K definido a priori, assume clusters de formato aproximadamente esférico e tamanho semelhante, é sensível à escala dos atributos e à inicialização dos centróides (mitigado com *n\_init=10*), e faz atribuição "dura", não modelando bem a incerteza em regiões de sobreposição entre grupos reais.

**Conclusão:** o K-Means recuperou de forma satisfatória a estrutura conhecida da base Iris com k=3, isolando perfeitamente uma espécie e separando as outras duas com poucos erros, coerentes com sua sobreposição biológica real. Tanto a escolha de K quanto a decisão de padronizar devem ser guiadas por métricas quantitativas e pela interpretação dos resultados, não aplicadas automaticamente.

**Link do vídeo de apresentação:** *[inserir link aqui antes da entrega]*